הצגת הבעיה

שבץ מוחי הוא מצב רפואי שבו זרימת דם לקויה למוח גורמת למוות של תאי מוח. גורם הסיכון העיקרי לשבץ הוא יתר לחץ דם. גורמי סיכון נוספים כוללים רמות כולסטרול גבוהות בדם, עישון טבק, השמנה, סוכרת, אירוע שבץ חולף קודם, מחלת כליות סופנית, ופרפור פרוזדורים.

באמצעות סט נתונים מאתר 'Kaggle' הנקרא 'Brain_Stroke.csv' ננסה לבצע זיהוי מוקדם של הפוטנציאל לקבלת שבץ מוחי. קובץ הCSV שוקל 280 קילו-בייטים, מכיל 11 עמודות(gender, age, hypertension, heart disease, ever-married, work-type, residence-type, avg-glucose-level, bmi, smoking status, stroke) ומבוסס על 54791 תאים, חלקם מספריים וחלקם איכותיים.

סטטיסטיקות תיאוריות

גיל

הגיל הממוצע של האנשים בנתונים הוא 43.42 שנים, עם סטיית תקן של 22.66 שנים, מה שמראה על פיזור רחב של הגילאים בקרב האוכלוסייה הנבדקת. הגיל המינימלי בנתונים הוא כ-0.08 שנים (בערך חודש), בעוד שהגיל המקסימלי מגיע ל-82 שנים. הטווח של הגילאים הוא 81.92 שנים, מה שמצביע על קשת רחבה של גילאים בנתונים.

יתר לחץ דם

רק כ-9.6% מהאנשים בנתונים סובלים מיתר לחץ דם, כפי שמראה הממוצע של משתנה זה (0.096). רוב האנשים בנתונים אינם סובלים מיתר לחץ דם, מה שמודגם גם על ידי העובדה שהשכיח של משתנה זה הוא 0. נתון זה מצביע על כך שרוב האוכלוסייה שנבדקה נמצאת ברמות לחץ דם תקינות.

מחלות לב

כ-5.5% מהאנשים סובלים ממחלות לב, כפי שעולה מהממוצע של משתנה זה (0.055). גם כאן, רוב האנשים בנתונים אינם סובלים ממחלות לב, כפי שמראה השכיח של משתנה זה (0). נתון זה מדגיש כי רוב האוכלוסייה אינה סובלת מבעיות לב.

רמת גלוקוז ממוצעת

רמת הגלוקוז הממוצעת בדם של האנשים בנתונים היא 105.94 מ"ג/ד"ל, עם סטיית תקן של 45.08 מ"ג/ד"ל, מה שמראה על פיזור רחב של רמות הגלוקוז. הטווח של רמות הגלוקוז נע בין 55.12 מ"ג/ד"ל ל-271.74 מ"ג/ד"ל, טווח רחב זה מצביע על שוני משמעותי ברמות הגלוקוז בקרב האוכלוסייה הנבדקת.

BMI - מדד מסת גוף

ה BMI-הממוצע בנתונים הוא 28.5, מה שמצביע על כך שרוב האנשים נמצאים בקטגוריית "עודף משקל". ה-BMIבנתונים נע בין 14.0 ל-48.9, עם טווח של 34.9, המראה על וריאציה משמעותית במסת הגוף בין האנשים שנבדקו. נתון זה מדגיש את השונות הרבה במצבי המשקל בקרב האוכלוסייה.

שבץ

כ-5% מהאנשים בנתונים עברו שבץ, כפי שמראה הממוצע של משתנה זה (0.0498). נתון זה מראה ששבץ הוא מצב רפואי נדיר יחסית בקרב האוכלוסייה שנבדקה. בנוסף, בטבלת החיתוך בין מגדר לשבץ נמצא כי השכיחות של שבץ מעט גבוהה יותר אצל גברים (5.2%) בהשוואה לנשים.(4.8%)

חיתוך גיל ממוצע לפי יתר לחץ דם ושבץ

עבור אנשים ללא יתר לחץ דם וללא שבץ, הגיל הממוצע הוא כ-40.29 שנים. לעומת זאת, אנשים ללא יתר לחץ דם אך עם שבץ הם בגיל ממוצע של 66.95 שנים, מה שמרמז על כך ששבץ נוטה להתרחש בגיל מבוגר יותר גם בקרב אלו שאין להם יתר לחץ דם. עבור אנשים עם יתר לחץ דם וללא שבץ, הגיל הממוצע הוא כ-61.55 שנים, ואילו אנשים עם יתר לחץ דם ושבץ הם בגיל ממוצע של 70.21 שנים. נתונים אלו מצביעים על כך שהשילוב של יתר לחץ דם וגיל מבוגר מגביר את הסיכון לשבץ.

Parameter	Age	Hypertension	Heart Disease	Avg Glucose Level	BMI	Stroke	Gender	Ever Married	Work Type
Count	4981	4981	4981	4981	4981	4981	4981	4981	4981
Mean	43.42	0.096	0.055	105.94	28.50	0.050	-	-	-
Std (Std Dev)	22.66	0.295	0.228	45.08	6.79	0.218	-	-	-
Min	0.08	0	0	55.12	14.0	0	-	-	-
25% (Q1)	25.0	0	0	77.23	23.7	0	-	-	-
50% (Median)	45.0	0	0	91.85	28.1	0	-	-	-
75% (Q3)	61.0	0	0	113.86	32.6	0	-	-	-
Max	82.0	1	1	271.74	48.9	1	-	-	-
Unique	-	-	-	-	-	-	2	2	4
Top	-	-	-	-	-	-	Female	Yes	Private
Frequency	-	-	-	-	-	-	2907	3280	2860

<u>ניתוח הסטנוגרמות לערכים מספריים בדאטה:</u>

- גיל :הגיל החציוני הוא 43 ,מה שמעיד על אוכלוסייה צעירה יחסית.
- יתר לחץ דם :רק 13% מהנבדקים סובלים מיתר לחץ דם.
- מחלות לב 10% :מהנבדקים סובלים ממחלות לב.
- רמת גלוקוז ממוצעת :רמת הגלוקוז הממוצעת החציונית היא 9.105.
- מדד מסת גוף :(BMI) מדד מסת הגוף החציוני הוא 3.28.
- שבץ מוחי :רק 5% מהנבדקים חוו שבץ מוחי.

<u>ניתוח חוזק המתאם על פי מטריצה:</u>

	age	hypertension	heart_disease	avg_glucose_level	bmi	stroke
age	1	0.28	0.26	0.24	0.37	0.25
hypertension	0.28	1	0.11	0.17	0.16	0.13
heart_disease	0.26	0.11	1	0.17	0.061	0.13
avg_glucose_level	0.24	0.17	0.17	1	0.19	0.13
bmi	0.37	0.16	0.061	0.19	1	0.057
stroke	0.25	0.13	0.13	0.13	0.057	1

מתאמים חזקים (יחסית):

- **גיל ו :BMI-** קיים מתאם חיובי בינוני עד חזק בין הגיל למדד מסת הגוף .ככל הנראה ,זהו אחד הקשרים החזקים ביותר במטריצה.

מתאמים בינוניים:

- **יתר לחץ דם, מחלות לב ושבץ מוחי :**בין המשתנים הללו קיימים מתאמים חיוביים חלשים עד בינוניים ,מה שמצביע על קשר בין מחלות לב וכלי דם.
- **רמת גלוקוז ממוצעת ו :BMI-**קיים מתאם חיובי חלש בין רמת הגלוקוז למדד מסת הגוף ,מה שמצביע על קשר אפשרי בין השמנה לרמות סוכר גבוהות.

מתאמים חלשים:

- **יתר לחץ דם ורמת גלוקוז ממוצעת :**למרות שקיים קשר בין מחלות לב וכלי דם ,הקשר בין יתר לחץ דם לרמת הגלוקוז הוא חלש יותר.
- **יתר לחץ דם ושבץ מוחי ורמת גלוקוז ממוצעת :**גם הקשרים בין יתר לחץ דם ושבץ מוחי לבין רמת הגלוקוז ממוצעת הם חלשים יחסית.

Main Analysis

1. **עץ החלטות –** פתחתי מודל ואלידי של עץ החלטות, לניבוי משתנה 'stroke' באמצעות המשתנים smoking_status וavg_glocuse_level.
   1. תחילה טענתי את הנתונים לכדי דאטה-פריים(df) כדי שנוכל לעבוד עליו.
   2. בזיהוי סוגי הערכים הבחנתי כי המשנה 'smoking status' הינו איכותי, לכן תרגמתי אותו למספרים נומריים כאשר:

```
d = {'formerly smoked': 0, 'never smoked': 1, 'smokes': 2, 'Unknown' : 3}
df['smoking_status'] = df['smoking_status'].map(d)
```

   3. לאחר מכן חלקתי את המשנים ל X1 וY1, על מנת שנוכל לחלק אותם לtrain וtest.

```
X1 = df[['smoking_status','avg_glucose_level']]
y1 = df['stroke']
```

   4. אופי החלוקה לtrain/test – כאשר החלוקה היא (75-25)

```
X1_train, X1_test, y1_train, y1_test = train_test_split(X1, y1, test_size=0.25, random_state=42)
```

   5. הגדרת העץ החלטות לפי המשתנים:

```
dtree3 = DecisionTreeClassifier(max_depth=3)
dtree3.fit(X1_train, y1_train)
```

   6. הגדרת משתנה חיזוי לטובת מטריצת בלבול:

```
y1_pred = dtree3.predict(X1_test)

cm1 = confusion_matrix(y1_test, y1_pred)

plt.figure(figsize=(8, 6))
sns.heatmap(cm1, annot=True, fmt='d', cmap='Blues', cbar=False, xticklabels=[0, 1], yticklabels=[0, 1])
plt.xlabel('Predicted Label')
plt.ylabel('True Label')
plt.title('Confusion Matrix - Decision Tree Model')
plt.show()
```

תוצאות המטריצה:

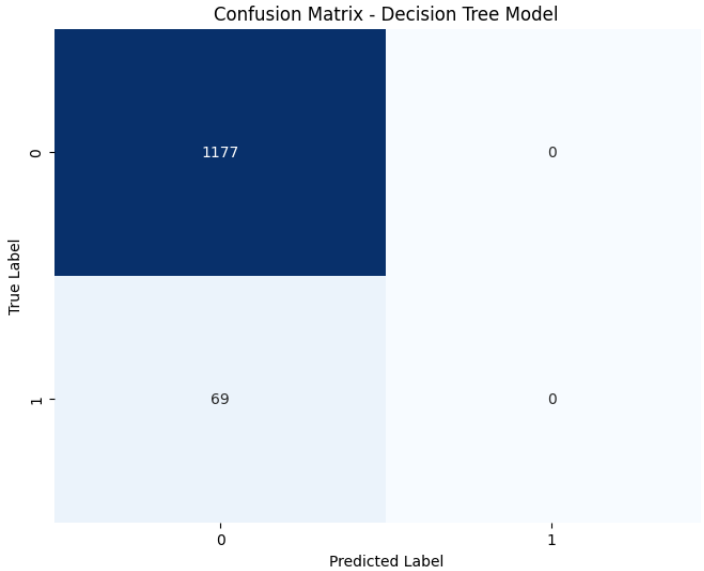

7. הגדרת מידת הדיוק:

```
accuracy1 = accuracy_score(y1_test, y1_pred)
print("Accuracy:", accuracy1)

Accuracy: 0.9446227929373997
```

8. קלאסיפיקציה:

```
print(classification_report(y1_test, y1_pred))

              precision    recall  f1-score   support

           0       0.94      1.00      0.97      1177
           1       0.00      0.00      0.00        69

    accuracy                           0.94      1246
   macro avg       0.47      0.50      0.49      1246
weighted avg       0.89      0.94      0.92      1246
```

9. ויזואליזציה של עץ ההחלטות

```
export_graphviz(decision_tree=dtree3,
out_file='C:\Residence_type.dot',
feature_names=X1_test.columns,
class_names=dtree3.classes_.astype(str),
leaves_parallel=True,
filled=True,
rotate=False,
rounded=True)
from graphviz import Source
Source.from_file('C:\Residence_type.dot')
```

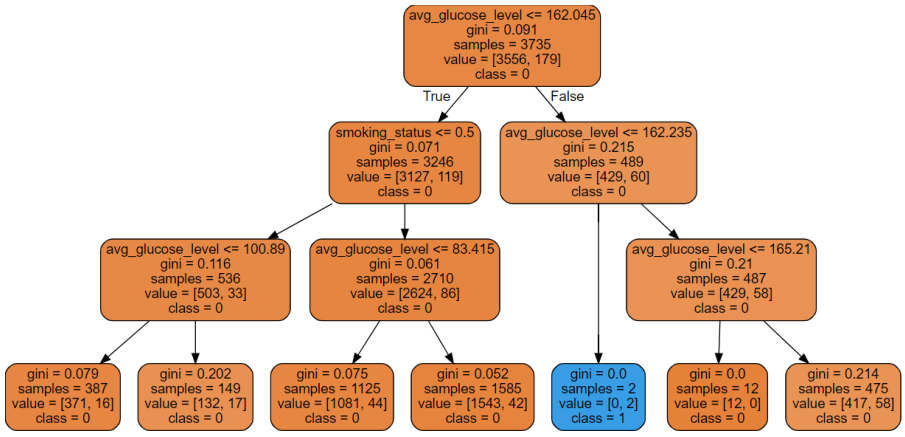

2. הרחבת עץ ההחלטות ושיפור הaccuracy

במודל השני של עץ ההחלטות אנו נדרשים לשיפור המודל הראשון על מנת להגיע למדד דיוק גבוהה יותר, באמצעות שינוי עומק העץ, וכן הוספת שדה אחד לבחירתי. להלן השלבים:

1. בחרתי להוסיף המשתנה "Ever_Married" כמשתנה מנבא נוסף, כמו כן המרתי את הערכים שלו לנומריים על מנת שאוכל לעבוד איתם:

```
d = {'Yes' : 0, 'No' : 1}
df['ever_married'] = df['ever_married'].map(d)
```

2. לאחר מכן חלקתי את המשנים ל X1 וY1, על מנת שנוכל לחלק אותם לtrain וtest.

```
X2 = df[['smoking_status','avg_glucose_level','ever_married']]
y2 = df['stroke']
```

3. חלוקת המשתנים ל train ו test, תחת ההוראה לחלוקה לפי 25-75. כמו כן, על מנת להגיע לתוצאות משופרות יותר,randomstate ירד ל0 במקום ל42 וכן נוספה רמה אחת לעץ max depth = 4

```
X2_train, X2_test, y2_train, y2_test = train_test_split(X2, y2, test_size=0.25, random_state=0)
dtree3 = DecisionTreeClassifier(max_depth=4)
dtree3.fit(X2_train, y2_train)
y2_pred = dtree3.predict(X2_test)
```

4. תוצאות מידת הדיוק:

```
accuracy2 = accuracy_score(y2_test, y2_pred)
print("Accuracy:", accuracy2)

Accuracy: 0.9510433386837881
```

5. ויזואליזצית העץ החדש

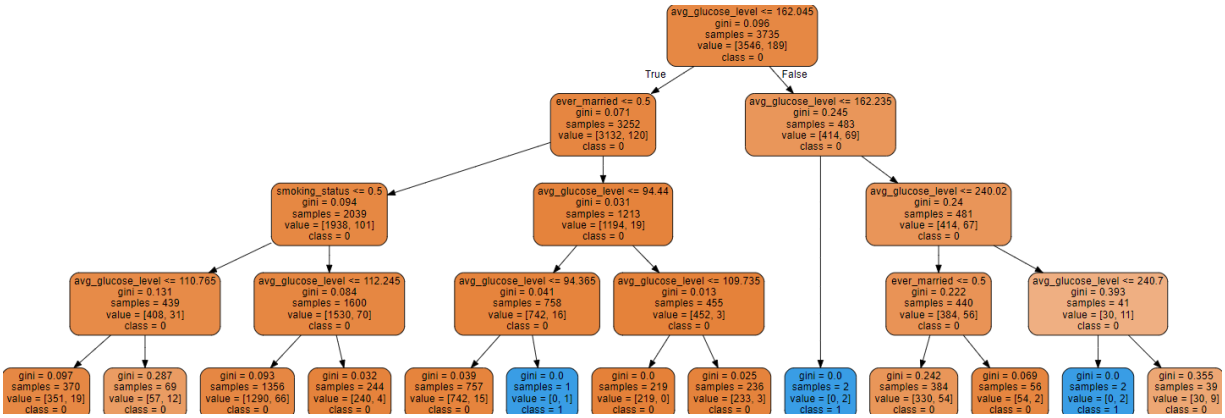

3. רגרסיה לוגיסטית

במודל הרגרסיה הלוגיסטית התבקשתי לנבא את המשתנה ever_married באמצעות המשתנים avg_glocuse_level וBMI.

1. ייצרתי עותק של הdata frame:

```
df4 = df.copy()
df4.head()
```

2. חלוקת המשתנים לקבוצות:

```
X4 = df4[['avg_glucose_level', 'bmi']]
y4 = df4['ever_married']
X4.head()
```

	avg_glucose_level	bmi
0	228.69	36.6
1	105.92	32.5
2	171.23	34.4
3	174.12	24.0
4	186.21	29.0

3. סטנדרטיזציה של הנתונים, קוד הזה נועד לתקנן את הנתונים כך שכל התכונות במערך הנתונים 4X יהיו בעלי ממוצע 0 וסטיית תקן 1:

```
from sklearn.preprocessing import StandardScaler
# Standardizing the data
scaler = StandardScaler()
scaler.fit(X4)
X4_scaled = scaler.transform(X4)
df_scaled = pd.DataFrame(X4_scaled, columns=X4.columns)
df_scaled.head()
```

	avg_glucose_level	bmi
0	2.723411	1.193238
1	-0.000523	0.589390
2	1.448529	0.869222
3	1.512650	-0.662492
4	1.780895	0.073909

4. חלוקת המשתנים ל train ו test, תחת ההוראה לחלוקה לפי 70-30

```
X4_train, X4_test, y4_train, y4_test = train_test_split(X4, y4, test_size=0.30, random_state=42)
```

5. בניית מודל הרגרסיה הלוגיסטית על פי החלוקה למשתני הניבוי:

```
from sklearn.linear_model import LogisticRegression
# Building the logistic regression model
logreg = LogisticRegression()
logreg.fit(X4_train, y4_train)
```

6. ניבוי מידת הדיוק וכן קלסיפיקציה:

```
# Predicting the target variable
y4_pred = logreg.predict(X4_test)

# Finding the accuracy score
accuracy4 = accuracy_score(y4_test, y4_pred)
print("Accuracy:", accuracy4)
```

```
Accuracy: 0.7397993311036789
```

```
print(classification_report(y4_test, y4_pred))
```

```
              precision    recall  f1-score   support

           0       0.77      0.87      0.82       989
           1       0.66      0.48      0.55       506

    accuracy                           0.74      1495
   macro avg       0.71      0.68      0.68      1495
weighted avg       0.73      0.74      0.73      1495
```

7. מטריצת בלבול:

```
# Calculate the confusion matrix
cm3 = confusion_matrix(y4_test, y4_pred)
# Plot the confusion matrix using seaborn's heatmap
plt.figure(figsize=(8, 6))
sns.heatmap(cm3, annot=True, fmt='d', cmap='Blues', cbar=False, xticklabels=[0, 1], yticklabels=[0, 1])
plt.xlabel('Predicted Label')
plt.ylabel('True Label')
plt.title('Confusion Matrix - Logistic Regression Model')
plt.show()
```

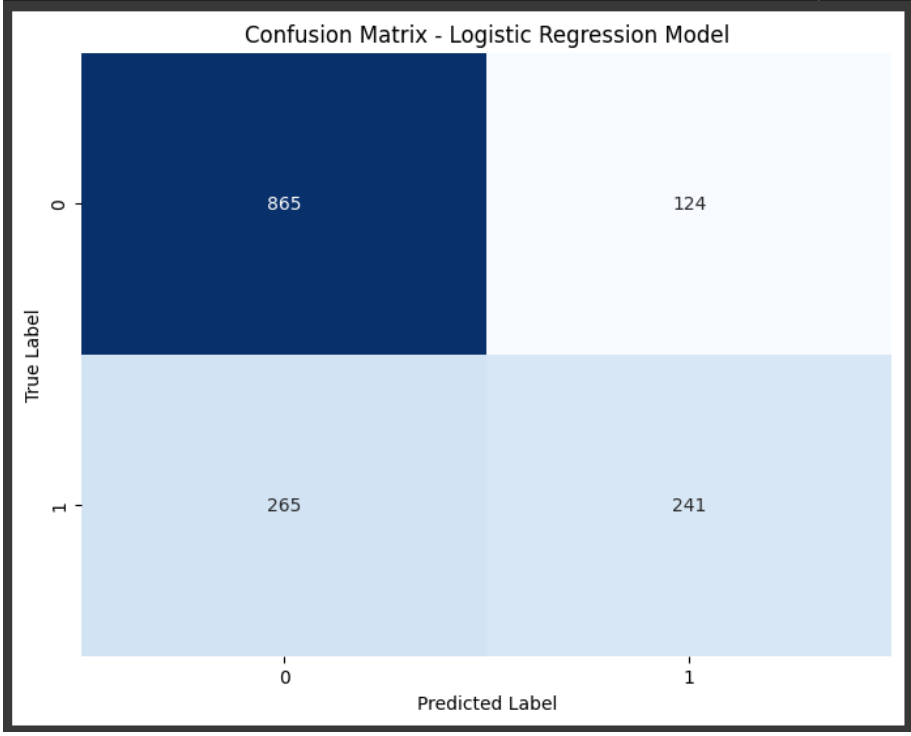

4. מודל k-nearest neighbor

התבקשתי לפתח מודל ואלידי לKNN, לניבוי המשתנה 'hypertension' באמצעות משתני הקובץ bmi ו age, על פי חלוקה ל train ו test של 20-80.

1. נחלק את המשתנים לקבוצות:

```
X5 = df[['age', 'bmi']]
y5 = df['hypertension']
```

2. סטנדריזציה של הנתונים:

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
scaler.fit(X5)
X5_scaled = scaler.transform(X5)
```

```
df_scaled = pd.DataFrame(X5_scaled, columns=X5.columns)
df_scaled.head()
```

	age	bmi
0	1.040584	1.193238
1	1.614270	0.589390
2	0.246250	0.869222
3	1.570141	-0.662492
4	1.658400	0.073909

3. חלוקת הקבוצות לtrain ו test לפי 20-80:

```
from sklearn.model_selection import train_test_split
# Splitting the data into train and test sets:
X5_train, X5_test, y5_train, y5_test = train_test_split(df_scaled, y5, test_size=0.20, random_state=42)
```

```
# Importing the KNeighborsClassifier class from the sklearn.neighbors library:
from sklearn.neighbors import KNeighborsClassifier
```

```
# Building the model
knn = KNeighborsClassifier(n_neighbors=7)
knn.fit(X5_train, y5_train)
```

```
KNeighborsClassifier
KNeighborsClassifier(n_neighbors=7)
```

4. מטריצת בלבול למודל KNN:

```
from sklearn.metrics import confusion_matrix, classification_report, accuracy_score
```

```
cm5 = confusion_matrix(y5_test, y5_pred)
```

```
plt.figure(figsize=(8, 6))
sns.heatmap(cm5, annot=True, fmt='d', cmap='Blues', cbar=False, xticklabels=[0, 1], yticklabels=[0, 1])
plt.xlabel('Predicted Label')
plt.ylabel('True Label')
plt.title('Confusion Matrix - KNN Model')
plt.show()
```

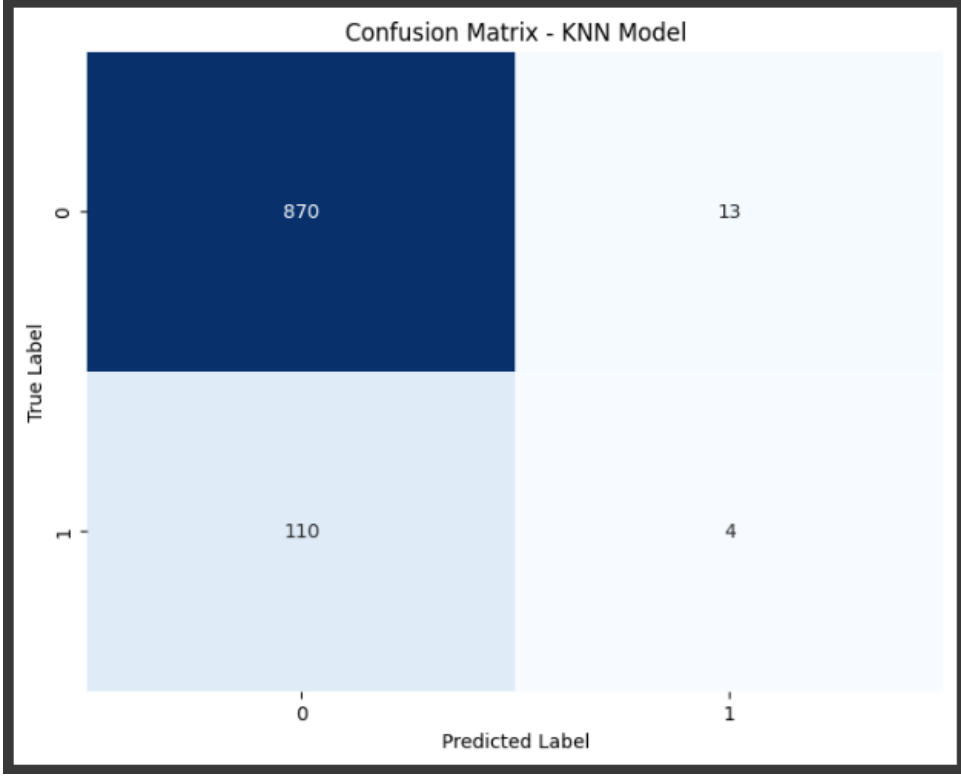

5. מידת הדיוק והקלסיפיקציה:

```
accuracy5 = accuracy_score(y5_test, y5_pred)
print("Accuracy:", accuracy5)
```

```
Accuracy: 0.876629889669007
```

```
print(classification_report(y5_test, y5_pred))
```

```
              precision    recall  f1-score   support

           0       0.89      0.99      0.93       883
           1       0.24      0.04      0.06       114

    accuracy                           0.88       997
   macro avg       0.56      0.51      0.50       997
weighted avg       0.81      0.88      0.83       997
```

ניתוח התוצאות:

עץ החלטה (Decision Tree)

מודל עץ ההחלטה השיג מידת דיוק גבוהה של 94.46% עד 95.10%, והצליח לסווג במדויק כמעט את כל המקרים שבהם לא התרחש שבץ. עם זאת, המודל כשל לחלוטין בזיהוי מקרים של שבץ, כפי שמשתקף במטריצת הבלבול, שבה ניכר כי המודל לא זיהה אף מקרה של שבץ נכון. מבנה עץ ההחלטות הציג תלות גבוהה ברמת הגלוקוז הממוצעת בדם ובסטטוס העישון של המטופלים, כאשר פיצולים אלו הובילו במרבית המקרים לסיווג של אי-שבץ. תוצאות אלו מצביעות על כך שהמודל מוטה באופן מובהק לזיהוי מחלקה שלילית (ללא שבץ) בלבד.

רגרסיה לוגיסטית (Logistic Regression)

מודל הרגרסיה הלוגיסטית הציג ביצועים מאוזנים יותר, עם מידת דיוק של 73.98%. המודל הצליח בצורה סבירה לזהות מקרים של אי-שבץ, אך התקשה בזיהוי מקרים חיוביים של שבץ. דוח הסיווג מצביע על כך שהמודל מצליח יותר בזיהוי מחלקה 0 (ללא שבץ) מאשר מחלקה 1 (עם שבץ), כאשר ערכי ה-Precision וה-Recall עבור מחלקה 1 הם נמוכים יותר. תוצאות אלו מעידות על יכולת חלקית בלבד של המודל לזהות מקרים של שבץ.

מודל שכן קרוב ביותר (K-Nearest Neighbors)

מודל ה-KNN השיג מידת דיוק של 87.66%, והראה ביצועים טובים בזיהוי מקרים של אי-שבץ, אך כמו המודלים האחרים, התקשה בזיהוי מקרים של שבץ. ממטריצת הבלבול עולה כי המודל זיהה נכון רק 5 מתוך 114 מקרים של שבץ. דוח הסיווג מראה כי למודל יש הטיה ברורה לטובת המחלקה השלילית (ללא שבץ), עם ערכי Precision ו-Recall נמוכים מאוד למחלקה החיובית (עם שבץ).

מסקנות

מסקנות הניתוח מצביעות על בעיה משותפת לכל המודלים שנבחנו: קושי ניכר בזיהוי מקרים של שבץ מוחי (מחלקה חיובית). כל המודלים הציגו ביצועים טובים בסיווג מקרים של אי-שבץ, אך כשלו בזיהוי המקרים שבהם התרחש שבץ, מה שמעיד על חוסר איזון במודל לטובת המחלקה השלילית. תוצאות אלו מצביעות על הצורך בשיפור האיזון בין המחלקות באמצעות טכניקות כגון איזון מחלקות, או בבחינת מודלים מתקדמים יותר שיכולים להתמודד טוב יותר עם מחלקות לא מאוזנות.